

STEP-D 방향 기획서

방송 콘텐츠 스포츠 자동 생성·다중 플랫폼 배포 B2B SaaS

파이프라인 · 아키텍처 · 로드맵

2026. 07. 15 | STEP AI 개발팀

발명신고서 「인공지능 기반 방송 영상의 스포츠 자동 생성 및 다중 플랫폼 배포 시스템 및 방법」 기반

1. 비전 — 한 문장

"긴 방송 영상을 올리면, 그 프로그램과 그 채널을 아는 AI가 터질 구간을 찾아 완성된 쇼츠로 만들고, 배포 결과에서 다시 배운다."

STEP-D는 방송사·MCN이 보유한 장편 콘텐츠(예능·드라마)를 자동 수집·변환하고, AI로 하이라이트를 선정해 세로형 숏폼으로 자동 편집·렌더링한 뒤, 유튜브·메타·SMR 계열에 배포하고 성과를 회수하는 B2B SaaS다.

핵심 전제 — B2B이기에 가능한 것. 고객은 이미 구독자와 활성 채널, 프로그램, 출연자 정보, 과거 배포 데이터를 가진 사업자다. 따라서 STEP-D는 익명 영상을 잘라주는 범용 도구(Opus Clip류)가 아니라, 프로그램의 서사와 채널의 성과 데이터가 누적될수록 추천이 정확해지는 "컨텍스트 자산 플랫폼"으로 설계한다.

인력의 역할은 '제작'에서 '검수·승인'으로 바뀐다. 60~90분 회차 1건 입력 시 완성 숏폼 최대 8개 + 썸네일·제목·메타데이터가 동시 산출된다.

2. 문제 정의

- **수작업 인건비 구조:** 변환 대기, 회차 전체 시청·클립 탐색, 자막 수작업, 플랫폼별 반복 가공·개별 업로드 — 회차당 수 시간~수십 시간, 물량에 비례해 인건비 선형 증가.
- **하이라이트 자동 추출의 품질 한계:** 음량·장면 전환 기반 종래 기술은 발화 문맥을 못 봐서 문장이 중간에 잘린다. 해외 도구는 한국어 종결어미 체계를 처리하지 못한다.
- **범용 영상 LLM 질의의 한계:** 타임스탬프 부정확, 드롭프레임 환경 싱크 오차, 전 구간 평가 시 비용 폭증.
- **후공정 자동화 부재:** 세로 변환 시 화자 이탈, PPL 수기 모니터링, 성과 취합 수작업, 데이터가 다음 콘텐츠에 환류되지 않음.

3. 제품 큰 그림 — 전체 루프

STEP-D의 모든 기능은 하나의 페루프다. 배포할수록 데이터가 쌓이고, 쌓일수록 다음 추천이 좋아진다.

[수집·변환] 마스터(MXF)/파일/URL → 유통규격 변환 + 분석용 프록시

↓

↓

[장면 이해] 인물·전사·서사 컨텍스트 주입 → 장면 요약 → 서사 타임라인

× 채널 적합 계수 × 인물·서사 계수 → (후보×채널) 매트릭스
↓ 운영자 원클릭 채택

↓

[배포] 회차 단위 스케줄링 → YouTube/Meta/SMR 일괄 업로드

다음 회차의 분석·추천 컨텍스트로

#	차별화	내용
1	한국어 종결어미 스냅	클립 경계를 발화 경계·종결어미(-다/-요/-죠)에 스냅 — 문장 중간 컷 구조적 방지. 해외 도구가 못 하는 것
2	비용·정밀도 계단	흑 사전 로컬 점수 → 상위 후보만 비전 LLM 평가(상한 고정) → 가중 융합. 회차당 AI 비용이 상수
3	STT 단일 원천	단어 단위 STT 1회 실행 결과를 후보 탐지·자막·제목·PPL이 공유 — 싱크 불일치 원천 제거
4	채널×프로그램 적합 추천	추천이 단일 랭킹이 아닌 (후보×채널) 매트릭스 — 같은 회차라도 Shorts/Reels/SMR별로 다른 구간이 상위
5	인물·서사 컨텍스트 엔진	출연자를 등록하면 '20대 남성'이 아닌 '23기 영숙'으로 확정 식별 — 회차가 갈수록 인물 서사·반응·성고가 쌓여 추천 근거가 됨

5. 파이프라인 상세 (발명신고서 구성 A~J)

구성	역할	기술 선택
A 수집·변환	MXF/파일/URL 수용, 리믹스 분기, 분석용 프록시 생성	ffmpeg + yt-dlp / 분기 로직 자체
B STT 축	단어 타임스탬프 STT 1회 → 전 단계 공유 (transcript 테이블)	Clova Speech 1차 (Whisper/Gemini 교체형 어댑터)
C 혹 후보	한국어 혹 사전(감탄/반전/질문/고조) 대조 + 로컬 점수, 후보 상한 30·중첩 0.35	100% 자체 (핵심 IP) + Kiwi 형태소
D 경계 스냅	종결어미·발화경계 스냅(룩백 8s/룩어헤드 10s), PTS 통일	100% 자체 (핵심 IP) + ffmpeg silencedetect
E 융합 평가	상위 20개×7프레임 비전 루브릭 → 0.70/0.30 융합 랭킹	Gemini + 융합 로직 자체
F 렌더링	9:16 리프레이밍(블러 배경), 자막 번인, 템플릿, render revision 캐시	ffmpeg+libass / 화자추적은 MediaPipe (2단계)
G 썸네일	후보 프레임 스코어링(선명도+얼굴) + 플랫폼 규격 최적화	ffmpeg + MediaPipe + sharp
H PPL	비전 상품 식별 × 음성 브랜드 언급 이중 신호 → 구간화·CSV 리포트	Gemini (+Video Intelligence 로고 검출 검토) / 교차 로직 자체
I 제목·메타	바이럴 패턴 5종 제목, 설명/태그, 무음 리포트	LLM + 프롬프트 자산 자체
J 배포·환류	회차 단위 스케줄링, 멀티플랫폼 업로드, 성과·댓글 수집·환류	YouTube Data API / Meta Graph API / SMR 어댑터

원칙: 특허 청구 대상 로직(B·C·D·E 융합·H 교차)은 전부 자체 구현. 오픈소스는 재료로만, 모델 추론은 관리형 API로(GPU 무운영). Ultralytics YOLO는 AGPL이라 배제 — 자체 검출기 필요 시 Apache 계열(RF-DETR 등).

6. 인물·서사 컨텍스트 엔진 (CX)

차별화 5번의 구현. 근본 기반 기술은 객체인식 — "샷 단위로 등장인물이 확정되는가"에 전체가 달려 있다.

6.1 다중 신호 인물 확정 스택

신호	기술	비고
얼굴 검출·매칭	MediaPipe + Gemini 폐쇄 후보군 매칭	"등록된 15명 중 누구" 문제 — 오픈셋보다 쉬움
네임 자막 OCR	PaddleOCR / Gemini	방송 특화 최강 신호 — 이름 자막이 이미 번인돼 있음
의상 re-ID	CLIP 임베딩	회차 내 의상 고정 → 뒷모습·원경 커버
발화 귀속	Clova 화자분리 × 입 움직임	STT 결과 재사용 — 누가 말했는지
샷 내 전파	ByteTrack	한 프레임 확정 → 샷 전체 전파, 호출 절감

6.2 루프

- **CX-1 캐스트 등록:** 프로그램·기수별 출연자 등록(방송사가 이미 보유) + 1화 분석 후 미등록 얼굴에 이름 붙이는 반자동 온보딩.
- **CX-2 장면 이해:** 샷당 1~2프레임에 [확정 인물 ID + 구간 전사 + 인물 KB 요약] 3중 컨텍스트 주입 → "영숙이 영호에게 노래를 불러주고 산책 중" 수준의 장면 레코드 → 서사 타임라인·회차 시놉시스.
- **CX-3 인물 KB:** 회차별 행동 로그, 페르소나 태그, 시청자 반응(댓글 인물별 감성·기대), 인물별 클립 성과 — 배포마다 자동 갱신.
- **CX-4 선정 통합:** 최종점수 = 융합점수 × 채널 적합 계수 × 인물·서사 계수. 댓글 기대 포인트("영숙 답장 언제 나옴?")와 미방영 장면 매칭 시 강한 부스트.
- **CX-5 환류:** 배포 성과·댓글이 KB로 → 다음 회차 분석·선정에 자동 반영.

게이트: CX1 착수 전 실제 1회분 PoC로 샷 태깅 정확도 90%+ 및 회차당 비용 실측 통과 필수.

7. 채널 분석·트렌드

7.1 채널 분석 6단계 (알고리즘 적합)

2026년 유튜브 Shorts는 임프레션당 시청시간·완주율이 지배 신호(30초 미만 ~65%, 30~60초 ~50% 완주가 노출 문턱).

- 수집: 리텐션 커브·트래픽 소스·시청층·engagedViews. 게시 후 48시간은 시간 단위 폴링 (초기 시딩 구간이 승부처).
- 정규화: 절대 조회수 금지 — 채널 최근 N개 중앙값 대비 배수 + 경과시간 정렬.
- 피쳐 조인: 혹 카테고리·길이·프리롤·제목 패턴·게시 시각·등장인물과 성과 결합.
- 진단: 초반 3초 이탈→시작 스냅 조정, 중반 이탈 지점↔전사 대조→혹 사전 보정, 완주율↔길이→ 목표 길이 재조정.
- 프로필 갱신: 승자 분포로 채널 소프트 성향 자동 보정.
- A/B 실험: '복사 후 수정' 변형판으로 시작점·제목·썸네일 실험.

7.2 트렌드 분석 (남의 잘 나가는 쇼츠 역분석)

트렌딩 쇼츠에 우리 분석 파이프라인(STT+비전)을 돌려 형식을 태깅 — 오프닝 구조(예: 무맥락 1~2초 콜드오픈), 자막 스타일, 컷 템포, 길이 분포. 트렌드 패턴 라이브러리에 반감기를 뒤 지난 유행 배제. 반영은 제안까지만 자동, 적용은 운영자 승인 (브랜드 톤 보호).

8. 시스템 아키텍처

8.1 현재 (구현됨)

[웹] Next.js 16 + React 19 — Vercel

| NEXT_PUBLIC_API_URL

[API] Hono — Cloud Run : 업로드/추천/채택/배포/YouTube OAuth

| enqueue (INSERT 1회)

[큐] job_queue — Cloud SQL(PostgreSQL) : SKIP LOCKED, dedupe, 백오프

| claim

[워커] GCE VM 상주 프로세스 : 채널 분석 파이프라인 (600s 제한 없음)

[스토리지] GCS(미디어) / Cloud SQL(엔티티·지표)

자체 Postgres 잡 큐와 VM 워커, 채널 지표 수집(일 단위 analytics 365일 백필, 영상 스탯 시간당 스냅샷)은 이미 프로덕션 수준으로 구현돼 있다.

8.2 목표 확장

- **업로드 경로 교체:** GB급 마스터 대응 — GCS 서명 URL로 클라이언트 직접 업로드, 서버는 완료 통지만 수신 (현행 메모리 버퍼 방식은 OOM 위험).
- **잡 체인 확장:** JobType에 media.ingest(프록시·리믹스) → analyze.stt → analyze.candidates → analyze.vision → clip.render → publish 추가. 단계별 중간 산출물 (전사·후보·점수·장면 레코드)을 전부 저장해 파라미터 튜닝 시 재실행 최소화.
- **어댑터 계층:** STT(Clova↔Whisper↔Gemini)·배포(YouTube/Meta/SMR)·비전을 인터페이스로 감싸 공급자 교체 가능하게.
- **신규 테이블:** transcript(단어·문장), candidate, scene_record, person/person_episode_log/person_reaction, metrics_snapshot, trend_pattern. 필요 시 pgvector 확장(얼굴·의상 임베딩).
- **워커 스케일:** ffmpeg 렌더 부하 증가 시 워커 VM 증설만으로 수평 확장 (SKIP LOCKED 설계가 이미 지원).

9. 로드맵

9.0 PoC 게이트 (1~2주, 버리는 코드)

- **PoC A 추천 품질:** 실제 회차 1개 → STT → 혹 사전 초안 + 경계 스냅 → 후보 20개 육안 평가.
종결어미 스냅이 정말 문장을 안 자르는지 검증.
- **PoC B 인물 식별:** 샷 분할 → Gemini 폐쇄군 매칭 ±OCR → 샷 100개 수동 채점. 90%+ 미달
시 CX 트랙 재설계.

단계	내용	비고
AP1 골격	서명 URL 업로드, 프록시 생성, ffmpeg 큐 이관, 잡 체인	기존 큐·워커 확장
AP2 진짜 추천	STT+transcript, 혹 사전 C, 경계 스냅 D, 프로그램·채널 프로파일 스키마 + 클립 인물 태그 자리 선반영	첫 체감 가치 — 영업 데모 시점
AP3 평가+렌더	비전 융합 평가 E + (후보×채널) 매트릭스, 9:16+자막 번인+ 템플릿 F, 썸네일 G	CX1~2 병행 (캐스트 등록, 장면 레코드)
AP4 배포 실행작	YouTube 실업로드, 스케줄러, 제목/메타 I, Meta 심사 착수, 채널 분석 수집 시작	CX3 병행 (인물 KB)
AP5 차별화 완성	PPL H, 화자추적 리프레이밍, 성과·댓글 환류, 트렌드 모듈, SMR 어댑터	CX4 (인물·서사 계수 통합)

운영 원칙: 소수 팀은 병렬로 벌리지 않고 PoC → AP1+AP2 → 첫 고객 회차 골드셋 평가 → 다음 단계의 한 줄로 간다. 고객사가 과거 수동 제작한 클립을 골드셋으로 확보해 자동 회귀 평가 체계를 AP2 부터 돌린다.

10. 리스크

리스크	대응
Clova STT 단어 타임스탬프 정밀도 미달	PoC A에서 실측 — 미달 시 Whisper word-level 전환 (어댑터로 교체 비용 최소화)
인물 식별 정확도 미달	PoC B 게이트. OCR·의상 신호 추가로 보강, 저신뢰 샷은 운영자 검수 큐
Meta 앱 심사 리드타임	AP4 이전 조기 신청
SMR 전달 방식 불명	계약·실무 채널로 조기 확인, 어댑터 인터페이스만 선설계
회차당 AI 비용	비용-계단 구조로 상한 고정 + 회차당 원가 산정 → B2B 과금 설계

리스크	대응
	근거
얼굴 인식 개인정보	방송사 계약에 출연자 초상 데이터 처리 근거 명시 (출연 계약상 권리 활용)
보안 사고 재발	시크릿 파일 커밋 금지 절차화(.gitattributes·pre-commit), .env 템플릿은 .example로만

11. 특허 연계

발명신고서 구성 A~J에 더해, 본 기획에서 도출된 확장 청구 후보를 변리사 검토 목록에 추가한다:

- 사전 등록 캐스트 기반 폐쇄 후보군 인물 확정 식별 + 화자 분리 교차에 의한 발화 귀속 (얼굴+ 네임자막 OCR+의상+화자 다중 신호 투표 구조 포함)
- 인물 지식 베이스(서사·반응·성과)의 회차 간 누적과 선정 계수 환류 페루프
- 시청자 댓글 기대 포인트와 미방영 장면 매칭에 의한 선정 부스트
- 채널 적합 계수에 의한 (후보×채널) 매트릭스 추천 — LLM 호출 증가 없는 채널별 랭킹